

Segmentación de Tumores Cerebrales con CNNs

Deep Learning

Máster Universitario de Investigación en Inteligencia Artificial

Iván Penedo

100012493@alumnos.uimp.es




Introducción

- Reto del ámbito médico.
- Segmentación automática de tumores cerebrales a partir de MRI.
- Métrica para evaluar: coeficiente Dice.
- Baseline de 0,6.

Descripción del conjunto de datos

Cada instancia con cuatro secuencias y una máscara.



Conjunto de datos ya dividido en:

- Entrenamiento.
- Validación.

Ampliación del conjunto de entrenamiento con transformaciones.

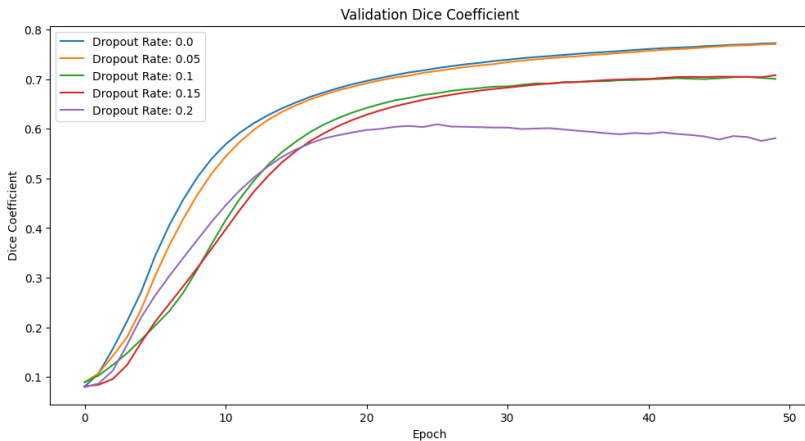
Arquitectura



- Entrada: 240x240x4.
- Codificador:
 - Convolución.
 - Pooling.
 - Batch normalization.
 - Dropout.
- Bloque central: Capa convolucional.
- Decodificador: Proceso inverso a codificador con UpSampling.
- Salida: Activación sigmoide para máscara binaria.


Diseño de la CNN1

Evolución del entrenamiento



Diseño de la CNN2

Arquitectura



- Entrada: 240x240x4.
- Codificador:
 - 2 Convoluciones.
 - Pooling.
 - Batch normalization.
 - Dropout.
- Bloque central: 2 capas convolucionales.
- Decodificador: Proceso inverso a codificador con UpSampling, y **skip connections**.
- Salida: Activación sigmoide para máscara binaria.


Diseño de la CNN2

Definición del entrenamiento

- Entrenamiento en dos fases:
 - Primeras 25 etapas: *learning rate* de $1 \cdot 10^{-4}$.
 - Últimas 25 etapas: Con las primeras 5 capas congeladas, *learning rate* de $1 \cdot 10^{-6}$. **Transfer learning**.
- EarlyStopping.
- Función de pérdida basada en coeficiente Dice.


Diseño de la CNN2

Evolución del entrenamiento




Diseño de la CNN2

Evolución del entrenamiento



Comparación de predicciones



Conclusiones

- Dos modelos de CNN para la segmentación de tumores cerebrales.
 - CNN1: Buenos resultados con arquitectura simple. Bajo coste computacional, pero poca definición de bordes en las regiones.
 - CNN2: Resultados superiores con especial captura en la forma de las máscaras.
- Pobre rendimiento de la técnica de dropout.
- Limitaciones por el entorno de Google Colab y el gran coste computacional del entrenamiento de CNNs.

Conclusiones

Trabajos futuros

- Ajustar *learning rate* en las primeras etapas.
- Investigar el uso de modelos preentrenados.
- Estudiar el uso adecuado de las capas de *dropout*.

Segmentación de Tumores Cerebrales con CNNs

Deep Learning

Máster Universitario de Investigación en Inteligencia Artificial

Iván Penedo

100012493@alumnos.uimp.es

